

**Projet M2 – Graphe CV–Job,
prédiction de liens par LLM et
classification des nœuds**

Projet de Graph Mining

Mariem Omrani

Anas Cherni

2026

Résumé

Ce projet étudie un système synthétique de rapprochement entre curriculum vitae et offres d'emploi sous la forme d'un graphe biparti. L'objectif est de combiner trois sources d'information complémentaires : la topologie du réseau, les communautés de compétences et la sémantique des textes. Après construction et audit du graphe, une analyse structurelle et une détection de communautés globales et internes sont réalisées. La prédiction de liens compare une méthode sémantique fondée sur des embeddings **all-MiniLM-L6-v2** à plusieurs scores structurels adaptés au caractère biparti. Sur un benchmark équilibré, le Katz tronqué à longueur 5 obtient la meilleure performance (ROC-AUC test 0,9445), devant le score sémantique (0,8676). Une évaluation de ranking beaucoup plus réaliste montre cependant que retrouver quelques correspondances pertinentes parmi près de 10 000 candidats par offre reste difficile. Un graphe enrichi est ensuite construit par consensus sémantique-Katz, puis exploité pour des tâches de classification de nœuds. Les résultats montrent que les embeddings classification-safe sont particulièrement informatifs pour la séniorité des CV et le domaine des offres, tandis que la topologie explique fortement les proxies de spécialisation. L'ensemble des conclusions doit néanmoins être interprété avec prudence en raison du caractère synthétique des données et de l'absence de vérité terrain future pour les liens ajoutés.


Mots-clés : Graph Mining, graphe biparti, prédiction de liens, embeddings, communautés, classification de nœuds.

1. Introduction et contexte

Le rapprochement entre un profil candidat et une offre d'emploi mobilise simultanément des informations textuelles – compétences, niveau d'expérience, responsabilités, formation – et des relations déjà observées entre profils et postes. Une approche purement tabulaire traite souvent chaque paire CV-Job de manière isolée. Elle décrit moins naturellement les régularités collectives : plusieurs CV peuvent cibler les mêmes familles de métiers, plusieurs offres peuvent attirer des profils proches, et des blocs professionnels cohérents peuvent émerger à l'échelle du réseau.

La modélisation en graphe permet de représenter explicitement ces interactions. Le réseau étudié est **biparti** : une partition contient les CV, l'autre les offres, et aucune arête ne relie deux CV ou deux Jobs entre eux. Cette structure autorise trois niveaux d'analyse complémentaires. La *topologie* décrit la connectivité, les composantes et les positions centrales ; les *communautés* révèlent des groupes de nœuds ou de compétences cohérents ; les *embeddings* transforment le texte en vecteurs numériques comparables sémantiquement.

La problématique étudiée est donc la suivante : *comment exploiter conjointement la structure d'un graphe biparti CV-Job, les communautés et les représentations sémantiques afin de prédire des correspondances manquantes et de classifier les profils et les offres ?* Le projet suit une chaîne expérimentale complète, depuis l'audit des données jusqu'à l'analyse finale des classifications, en passant par la comparaison rigoureuse des méthodes de prédiction de liens et par un scénario d'enrichissement du graphe.



Pipeline méthodologique du projet

Figure 1 – Pipeline méthodologique du projet, de la préparation des données à l'analyse finale.

2. Données et modélisation du graphe

2.1 Dataset synthétique

Le dataset `michaelozon/candidate-matching-synthetic` fournit trois ensembles : 10 000 CV, 2 500 offres d'emploi et 2 500 enregistrements de matches, chacun associé à une liste de CV pertinents. Le passage au format long produit exactement 75 000 couples positifs CV–Job uniques, soit 30 correspondances par Job. L'audit initial ne détecte ni valeur manquante, ni doublon, ni référence invalide entre les tables.

Les CV contiennent notamment le rôle, la séniorité, le nombre d'années d'expérience, l'industrie, le niveau d'éducation, les compétences, un résumé et des puces d'expérience. Les Jobs comportent le titre, la séniorité, l'industrie, les compétences obligatoires et facultatives, la description, les responsabilités et les exigences. La donnée est entièrement synthétique ; cette propriété constitue une limite structurante, car les régularités de degrés, de texte et de matching peuvent être plus nettes que dans un marché de l'emploi réel.

2.2 Graphe biparti CV–Job

Le graphe simple non orienté s'écrit

$$G = (V, E), \quad V = V_{CV} \cup V_{Job}, \quad V_{CV} \cap V_{Job} = \emptyset,$$

où chaque arête de E relie nécessairement un CV à un Job. Il contient 12 500 nœuds et 75 000 arêtes observées.

La densité pertinente est la densité bipartite :

$$D_{bip} = \frac{|E|}{|V_{CV}| |V_{Job}|} = \frac{75\,000}{10\,000 \times 2\,500} = 0,003.$$

Le dénominateur correspond aux 25 millions de paires CV–Job admissibles. Une densité générique sur toutes les paires de nœuds compterait à tort les paires CV–CV et Job–Job, qui sont interdites par construction.

Tableau 1 - Synthèse du dataset après audit initial.

Indicateur	Valeur
Nombre de CV	10 000
Nombre de Jobs	2 500
Enregistrements de matches	2 500
Correspondances CV-Job positives uniques	75 000
CV pertinents par Job	30
Rôles distincts côté CV	24
Industries distinctes	10
Compétences uniques	73 (CV) ; 73 (Jobs)
Qualité des données	Aucun problème détecté

Le notebook d'audit montre que chaque Job possède exactement 30 CV pertinents et qu'aucune valeur manquante, aucun doublon ni aucune référence invalide n'est détecté. Lors de la construction du graphe, les 75 000 couples positifs deviennent donc 75 000 arêtes. Le degré initial de chaque Job vaut 30 ; cette régularité vient du caractère synthétique des données. Le graphe comporte 36 composantes et 29 CV isolés, et sa plus grande composante regroupe 3 102 nœuds (24,8 %).




Figure 2 – Schéma illustratif de la modélisation bipartite : les arêtes relient uniquement des CV à des Jobs.

3. Analyse structurelle et communautés

3.1 Structure du réseau

Le degré moyen global vaut 12, mais cette valeur masque l'asymétrie entre les partitions : un CV possède en moyenne 7,5 voisins alors qu'un Job en possède 30. Un degré CV élevé signifie qu'un profil apparaît dans plusieurs correspondances observées ; inversement, un degré nul correspond à un profil sans aucun match enregistré. Les Jobs n'ont initialement aucune dispersion de degré, ce qui limite l'intérêt de certaines mesures dépendant fortement de l'hétérogénéité des degrés.

Sur la plus grande composante, un échantillonnage de 100 paires de nœuds donne une distance moyenne approximative de 4,38, avec une médiane de 4, un minimum de 2 et un maximum de 6. PageRank ($\alpha = 0,85$) et une betweenness approximée à partir de 100 sources complètent l'analyse des positions. PageRank favorise les nœuds reliés à des voisins eux-mêmes importants, tandis que la betweenness repère les nœuds traversés par de nombreux plus courts chemins. Le clustering triangulaire classique n'est pas informatif ici : un graphe biparti pur ne contient aucun triangle.

3.2 Communautés globales

La détection des communautés globales utilise **Label Propagation**. Chaque nœud part avec un label propre, puis adopte itérativement le label dominant dans son voisinage. L'ordre de mise à jour étant aléatoire, cinq seeds ont été testées et la partition de modularité maximale a été retenue. La qualité d'une partition est mesurée par la modularité standard :

$$Q = \sum_c \left[\frac{l_c}{m} - \left(\frac{k_c}{2m} \right)^2 \right],$$

où l_c est le nombre d'arêtes internes à la communauté c , k_c la somme de ses degrés et m le nombre total d'arêtes. Une valeur élevée indique davantage d'arêtes internes que ce qu'attendrait un modèle aléatoire conservant approximativement les degrés.

La partition retenue compte 37 communautés et atteint $Q \approx 0,8725$. Elle se compose de huit grands blocs professionnels et de 29 communautés singleton correspondant aux CV isolés. Les grands groupes sont sémantiquement cohérents : Software Engineering, Finance & Accounting, Product Management, Data & Analytics, Sales / Business Development, Marketing, Operations / Project Management et Customer / Technical Support. Cette structure suggère que le graphe synthétique est principalement organisé par familles de métiers et ensembles de compétences. La modularité reste toutefois la version standard, et non une modularité spécialement conçue pour les graphes bipartis.

3.3 Communautés internes de compétences

Un second graphe pondéré est construit à partir des compétences des CV. Chaque nœud représente une compétence ; une arête relie deux compétences lorsqu’elles apparaissent ensemble dans au moins un CV ; son poids correspond au nombre de cooccurrences. Le graphe contient 73 nœuds, 359 arêtes, deux composantes et aucun isolé. Une Label Propagation pondérée identifie huit communautés avec une modularité pondérée d’environ 0,7184.

Table 2 – Communautés de compétences détectées et exemples représentatifs.

Communauté	Taille	Domaine	Exemples de compétences
0	10	Marketing	SEO, Google Ads, Email Marketing, Copywriting, A/B Testing
1	10	Sales / CRM	CRM, Negotiation, Prospecting, Lead Generation, Closing
2	10	Projet / opérations	Jira, Asana, Reporting, KPIs, Risk Management
3	10	Software Engineering	Python, Java, Git, Docker, REST APIs
4	10	Support client	Zendesk, Ticketing, Troubleshooting, SLA, Documentation
5	9	Product Management	Agile, Roadmap, Product Strategy, User Research
6	8	Data / BI	SQL, Pandas, Tableau, Power BI, Statistics
7	6	Finance	Accounting, Valuation, Budgeting, Financial Modeling

Chaque CV est ensuite projeté sur ces groupes afin de produire des features internes : nombre de communautés couvertes, communauté dominante, part dominante et entropie. L’entropie est définie par

$$H = - \sum_c p_c \log p_c,$$

où p_c est la proportion des compétences du CV appartenant à la communauté c . Une entropie faible correspond à des compétences concentrées dans un nombre réduit de domaines ; une entropie plus élevée traduit une plus grande diversité. Les CV couvrent en moyenne 1,515 communauté de compétences, avec une entropie moyenne de 0,221 et une part dominante moyenne de 0,912. Environ 68,4% des CV appartiennent à une seule communauté de compétences.

4. Prédiction de liens

4.1 Protocole expérimental et contrôle des fuites

Les 75 000 arêtes positives sont divisées en 60 000 liens d’entraînement, 7 500 de validation et 7 500 de test. Une contrainte warm-start protège la connectivité : un lien n’est retiré que si ses deux extrémités conservent au moins un lien dans le graphe d’entraînement. Ainsi, aucun nouvel isolé n’est créé. Des négatifs équilibrés sont échantillonnés en excluant l’ensemble complet des 75 000 positives, de sorte qu’un lien de validation ou de test ne puisse jamais être considéré comme négatif.

Toutes les méthodes sont évaluées sur les mêmes paires. Les scores structurels utilisent exclusivement le graphe d’entraînement à 60 000 arêtes ; exploiter la topologie du graphe complet révélerait indirectement les liens cachés. Le benchmark de comparaison est volontairement équilibré 50/50. Il facilite la comparaison méthodologique, mais il ne reproduit pas le taux naturel : sur 25 millions de paires CV–Job possibles, seulement 75 000 sont positives, soit environ 0,3%.

4.2 Score sémantique par embeddings

Les textes CV et Job sont encodés avec `sentence-transformers/all-MiniLM-L6-v2` en vecteurs de dimension 384, normalisés en norme L_2 . La similarité cosinus entre deux embeddings x et y est

$$s_{sem}(x, y) = \frac{x \cdot y}{\|x\| \|y\|}.$$

Elle mesure une proximité sémantique, pas une probabilité calibrée. Le seuil maximisant le F1 sur validation, 0,5489, est gelé avant l'évaluation finale. Sur test, la méthode atteint une ROC-AUC de 0,8676, une Average Precision de 0,8404 et un F1 de 0,8162. Les positifs ont un score moyen d'environ 0,651 contre 0,502 pour les négatifs, ce qui montre une séparation réelle mais imparfaite des distributions.

4.3 Scores structurels adaptés au biparti

Preferential Attachment utilise simplement $d(r)d(j)$ et reste directement défini sur le graphe biparti. En revanche, Common Neighbors et Adamic-Adar standards ne sont pas informatifs pour une paire CV-Job, car

$$N(CV) \subseteq Jobs, \quad N(Job) \subseteq CV, \quad N(CV) \cap N(Job) = \emptyset.$$

Le projet introduit donc des adaptations explicites. **CN3** compte les marches de longueur 3 de la forme CV $\rightarrow$ Job $\rightarrow$ CV $\rightarrow$ Job. L'Adamic-Adar biparti mesure la proximité du CV candidat avec les CV déjà reliés au Job, en pondérant moins les Jobs intermédiaires très connectés.

Katz repose sur l'ensemble des marches entre deux nœuds, pénalisées par leur longueur :

$$Katz(i, j) = \sum_{\ell=1}^{\infty} \beta^{\ell} (A^{\ell})_{ij}.$$

Dans un graphe biparti, un CV et un Job ne peuvent être reliés que par des longueurs impaires. Pour éviter une inversion dense et conserver une implémentation reproductible, le score utilisé est un **Katz tronqué à $L = 5$** :

$$Katz_5(r, j) = \beta^3 W_3(r, j) + \beta^5 W_5(r, j),$$

avec $\beta = 0,9/\lambda_{max}$ choisi uniquement sur validation. Il ne s'agit donc pas du Katz infini exact.

4.4 Comparaison sur le benchmark équilibré

Table 3 – Performances test des méthodes de prédiction de liens sur le benchmark équilibré.

Méthode	ROC-AUC	Average Precision	F1
Cosinus sémantique	0,8676	0,8404	0,8162
Preferential Attachment	0,5253	0,5192	0,6671
CN3 bipartite adapté	0,8959	0,8592	0,8929
Adamic-Adar bipartite adapté	0,8963	0,8611	0,8929
Katz tronqué L=5	0,9445	0,9033	0,9440

Katz tronqué fournit le meilleur classement. Le signal semble particulièrement fort parce que les correspondances synthétiques créent des motifs de marches courtes très réguliers. CN3 et Adamic-Adar sont presque équivalents, ce qui suggère que la pondération logarithmique ajoute peu lorsque les degrés des Jobs sont fortement homogènes. Preferential Attachment reste proche du hasard. Les scores sémantique et Katz ne sont que modérément corrélés (Spearman d'environ 0,636 sur test), ce qui confirme qu'ils capturent des informations différentes.




Figure 3 – Comparaison des méthodes de prédiction de liens sur le jeu de test équilibré.

4.5 Ranking réaliste et effet du faible taux de base

Une seconde évaluation classe, pour chaque Job, les quelques liens positifs cachés parmi l'ensemble des CV admissibles. Les valeurs $K \in \{1, 3, 5, 10, 20, 50\}$ sont étudiées sur validation, et le consensus retient $K = 50$. Sur test, le sémantique obtient $\text{Precision@50} = 0,00284$, $\text{Recall@50} = 0,04363$ et $\text{HitRate@50} = 0,1344$. Katz atteint respectivement 0,00325, 0,04992 et 0,1490. L'intersection des deux Top-50 produit 5 024 recommandations test, avec une précision de 0,00358, un rappel de 0,00240 et une couverture d'environ 88,8% des Jobs évaluables.

Ces valeurs ne contredisent pas la ROC-AUC élevée. Le benchmark équilibré demande essentiellement de classer correctement un positif et un négatif échantillonné. Le ranking opérationnel demande de retrouver quelques positifs parmi plusieurs milliers de candidats, avec un taux de base extrêmement faible. Cette différence d'échelle constitue l'un des résultats méthodologiques les plus importants du projet : une excellente séparation statistique sur un benchmark artificiellement équilibré ne garantit pas une précision absolue élevée en recommandation réelle.




Figure 4 – Contraste entre le benchmark équilibré et le ranking réaliste pour les méthodes sémantique et Katz.

5. Enrichissement du graphe

Après gel de toutes les décisions sur validation, l'enrichissement repart du graphe complet observé à 75 000 arêtes. Pour chaque Job, une nouvelle paire doit appartenir simultanément au Top- K sémantique

et au Top- K Katz, avec un score Katz strictement positif. Cette règle de consensus est volontairement conservatrice : une arête candidate doit recevoir un soutien à la fois textuel et topologique.

Le consensus ajoute 5 347 liens candidats. Le graphe passe ainsi de 75 000 à 80 347 arêtes ; sa densité de 0,003000 à 0,003214 ; le degré moyen CV de 7,5 à 8,0347 et le degré moyen Job de 30 à 32,1388. Les 36 composantes et les 29 isolés restent inchangés. L’enrichissement doit toutefois être interprété comme un **scénario expérimental** : les nouveaux liens ne sont pas des matches confirmés et la faible précision absolue observée dans le ranking réel interdit de les assimiler à une nouvelle vérité terrain.

6. Représentation et classification des nœuds

6.1 Features et prévention des fuites

Trois familles de représentations sont utilisées. Les **features structurelles** comprennent le degré, la centralité de degré bipartite, PageRank, l’isolement, la taille de composante, la communauté globale et sa taille. Les **features internes** des CV comprennent notamment le nombre de skills, le nombre de communautés de compétences, la communauté dominante, sa part et l’entropie. Enfin, les **features sémantiques** sont des embeddings de 384 dimensions.

Une précaution spécifique est nécessaire pour la classification. Les embeddings utilisés en link prediction contenaient directement **seniority** et **industry**. Les réutiliser tels quels aurait introduit la cible dans les prédicteurs. De nouveaux embeddings *classification-safe* sont donc construits avec le même modèle : le champ **seniority** est retiré des textes CV ; **seniority** et **industry** sont retirés des textes Job. Le preprocessing (StandardScaler et OneHotEncoder) est ajusté uniquement sur le train 70%, avec validation et test 15%/15% stratifiés. Les communautés sont traitées comme variables catégorielles. Aucune PCA globale ni GNN n’est utilisé.

Deux pseudo-labels de spécialisation sont également définis. Pour les CV, un profil est *specialized proxy* si ses compétences appartiennent à une seule communauté de skills, et *generalist proxy* s’il en couvre plusieurs. Pour les Jobs, la même logique est appliquée aux compétences obligatoires. Il ne s’agit pas d’annotations humaines. Pour éviter toute circularité, les tâches de spécialisation utilisent uniquement des features structurelles globales, jamais les variables directement dérivées des skills ni des embeddings contenant ces skills.

6.2 Méthodes et résultats

Une Dummy baseline majoritaire sert de référence. Logistic Regression fournit un modèle linéaire régularisé et Random Forest agrège 300 arbres. Le choix du modèle est réalisé exclusivement sur validation à partir du macro-F1, puis de la balanced accuracy et de la simplicité. Une méthode relationnelle semi-supervisée, inspirée du cours, fixe les labels des nœuds train et met à jour les distributions des nœuds masqués à partir de la moyenne de leurs voisins ; elle exploite donc la topologie sans feature locale.

Table 4 – Meilleures configurations principales, sélectionnées sur validation.

Tâche	Méthode	Features	Macro-F1 test	Accuracy
CV seniority	Régression logistique	Sémantique safe	0,8769	0,8773
CV specialization proxy	Régression logistique	Structure originale	0,9393	0,9453
Job seniority	Random Forest	Structure originale	0,2989	0,2987
Job industry	Régression logistique	Sémantique safe	1,0000	1,0000
Job specialization proxy	Régression logistique	Structure originale	0,8982	0,9147

Pour la séniorité des CV, le texte classification-safe fournit l’essentiel du signal : les rôles, responsabilités et éléments d’expérience restent informatifs même après suppression du label direct. L’ensemble complet

atteint 0,8802 de macro-F1 sur test, mais n'était pas la configuration gagnante sur validation. Les communautés internes seules restent beaucoup plus faibles (0,3122), ce qui montre qu'une simple concentration de skills ne suffit pas à reconstituer le niveau d'expérience.

La séniorité des Jobs reste au contraire difficile. La meilleure configuration sélectionnée atteint seulement 0,2989 de macro-F1 ; même l'ensemble complet ne dépasse que 0,3351 au test. À l'opposé, le domaine des Jobs atteint 1,0000 avec l'embedding safe. Ce résultat doit être lu avec prudence : bien que le champ `industry` ait été retiré, les titres, descriptions et compétences rendent le domaine presque explicite dans un dataset synthétique.

Les proxies de spécialisation sont fortement associés à la topologie : 0,9393 de macro-F1 pour les CV et 0,8982 pour les Jobs. Le classifieur relationnel confirme cette homophilie avec des macro-F1 originaux de 0,9016 et 0,8981. En revanche, il reste proche du hasard pour la séniorité (0,3296 CV ; 0,3485 Job) et pour l'industrie (0,0963 CV ; 0,0825 Job). La topologie est donc très informative pour certaines cibles mais pas universellement.




Figure 5 – Performances test des meilleures configurations de classification sélectionnées sur validation.

7. Impact de l'enrichissement et analyse des profils

L'effet de l'enrichissement est mesuré à splits identiques par

$$\Delta F1 = F1_{enrichi} - F1_{original}.$$

Il n'est pas uniformément positif. Le Job seniority structurel gagne environ +0,0013 et la version All Safe +0,0069 ; le Job industry structurel gagne +0,0683 ; à l'inverse, le CV seniority structurel perd -0,0355. Les deux tâches de spécialisation restent pratiquement inchangées. L'enrichissement ne peut donc pas être présenté comme une amélioration générale de la classification.




Figure 6 – Variation du macro-F1 entre graphes enrichi et original pour plusieurs tâches et familles de features.

La partition communautaire globale reste presque identique : 37 communautés avant et après, modularité de 0,872458 à 0,872558, ARI 0,999636 et NMI 0,999364. ARI et NMI proches de 1 indiquent que les regroupements sont quasi identiques malgré l'arbitraire des numéros de communautés. Les liens prédits modifient donc certains degrés, mais ne réorganisent pas les grands blocs professionnels.

Parmi les CV, 6 841 sont classés *specialized proxy* et 3 159 *generalist proxy*. Les profils polyvalents sont caractérisés descriptivement par un nombre élevé de communautés de skills et une entropie importante ; les profils structurellement atypiques sont repérés par des degrés ou PageRank extrêmes à l'intérieur de leur communauté, ou par une forte variation de degré après enrichissement. Ces catégories ne constituent aucun jugement sur la qualité d'un candidat : elles décrivent seulement des positions ou diversités inhabituelles dans le système synthétique.

8. Discussion, limites et perspectives

Nature synthétique des données. Les matches sont générés à partir d'attributs fortement liés aux compétences. La régularité parfaite du degré des Jobs, la forte cohérence des communautés et la séparation parfaite du domaine peuvent donc être artificiellement élevées. Les résultats mesurent la cohérence d'un générateur synthétique, pas la performance d'un système de recrutement réel.

Benchmark équilibré et faible taux de base. Le benchmark 50/50 est utile pour comparer des scores dans un cadre contrôlé, mais il ignore un taux positif naturel de seulement 0,3%. Le ranking réaliste montre que quelques positifs doivent être retrouvés parmi des milliers de CV. La différence entre AUC élevée et faible précision absolue est donc attendue et doit être explicitement prise en compte avant tout déploiement.

Nature des non-liens. Une paire absente du dataset n'est pas nécessairement un mauvais match ; elle peut simplement être non observée. Le projet assimile les paires non listées à des négatifs pour construire un benchmark, mais cette hypothèse est plus forte que ce qu'on pourrait affirmer avec de vraies données de recrutement.

Adaptation des méthodes structurelles. CN3 et Adamic-Adar sont des adaptations nécessaires au caractère biparti. Ils ne doivent pas être confondus avec l'application directe des formules standards. De même, le Katz utilisé est tronqué aux longueurs 3 et 5 : il ignore les marches plus longues et reste une approximation choisie pour des raisons de coût et de lisibilité.

Communautés et pseudo-labels. Label Propagation est non déterministe ; plusieurs seeds limitent cette variabilité sans l'annuler complètement. La modularité évaluée est la modularité standard, dont le modèle nul n'est pas spécialement biparti. Par ailleurs, *specialized/generalist* est un proxy dérivé des communautés de skills, et non une vérité terrain humaine.

Enrichissement et fuite indirecte. Les 5 347 liens ajoutés ne sont pas des matches confirmés. Leur sélection repose en partie sur les embeddings de link prediction, qui contenaient initialement **seniority** et **industry**. Les features structurelles du graphe enrichi peuvent donc transporter indirectement de l'information liée aux futures cibles. Pour cette raison, le graphe original reste la référence scientifique la plus propre ; le graphe enrichi est interprété comme une analyse exploratoire secondaire.

Les perspectives prioritaires sont une validation sur données réelles et anonymisées, une séparation temporelle des matches, une véritable évaluation cold-start pour de nouveaux CV ou Jobs, la calibration des scores, l'apprentissage de ranking supervisé et une validation humaine des recommandations. Un GNN constituerait une extension logique après stabilisation de ces protocoles ; aucun GNN n'a été exécuté dans cette étude.

9. Conclusion

Le graphe CV–Job synthétique présente une structure communautaire forte, organisée principalement par familles professionnelles et ensembles de compétences. Huit grands blocs globaux et huit communautés de skills fournissent des représentations complémentaires : la première décrit la position d'un nœud dans le réseau, la seconde la concentration ou la diversité des compétences d'un profil.

Pour la prédiction de liens, le Katz tronqué à $L = 5$ domine le benchmark équilibré avec une ROC-AUC test de 0,9445. Le score sémantique est moins performant mais apporte un signal complémentaire, seulement modérément corrélé à Katz. Le ranking réaliste révèle toutefois la difficulté opérationnelle du problème : l'excellent AUC ne se traduit pas en précision absolue élevée lorsqu'il faut retrouver quelques bons profils parmi presque 10 000 candidats. L'enrichissement par consensus modifie légèrement les degrés sans changer sensiblement les communautés, et ses effets sur la classification sont hétérogènes.

Pour la classification, les embeddings classification-safe sont particulièrement utiles pour la séniorité CV et le domaine des Jobs, tandis que la topologie retrouve fortement les proxys de spécialisation. La séniorité des Jobs reste difficile. L'ensemble du projet montre ainsi l'intérêt de combiner structure et sémantique, mais aussi la nécessité d'évaluer chaque méthode dans un protocole proche des conditions réelles. Une validation temporelle, cold-start et sur données réelles est indispensable avant toute utilisation opérationnelle.

Références

- [1] *Projet M2 – Graphe CV–Job, prédiction de liens par LLM et classification des nœuds*. Cahier des charges fourni avec le projet, 2026.
- [2] Support de cours *Machine Learning – Link Prediction*, documents fournis dans le cadre du module de Graph Mining.
- [3] Support de cours *Machine Learning – Node Classification*, documents fournis dans le cadre du module de Graph Mining.
- [4] Dataset Hugging Face, `michaelozon/candidate-matching-synthetic`. <https://huggingface.co/datasets/michaelozon/candidate-matching-synthetic>
- [5] Modèle Sentence Transformers, `sentence-transformers/all-MiniLM-L6-v2`. <https://huggingface.co/sentence-transformers/all-MiniLM-L6-v2>
- [6] Documentations des bibliothèques utilisées : NetworkX, scikit-learn, SciPy et sentence-transformers.